Modelagem e Métodos de Busca Linear em Otimização Irrestrita:

Estudo dos retornos VALE3–Ibovespa e análise de 27 experimentos numéricos

João Ivo Rocha Alves
Matrícula: 581734
Bacharelado em Ciência de Dados – Universidade Federal do Ceará
Disciplina: Programação Não Linear
Professor: Ricardo Coelho

Outubro de 2026

Resumo

Este trabalho integra a formulação de um problema real de otimização irrestrita e a implementação de métodos de busca linear em funções de teste clássicas, conforme o projeto computacional da disciplina Programação Não Linear. Na parte aplicada, modela-se a relação entre os retornos percentuais por pregão da ação VALE3 e do Ibovespa por meio de uma função quadrática de mínimos quadrados com dois parâmetros. A amostra contém 1.246 pares de retornos, de 4 de janeiro de 2021 a 30 de dezembro de 2025. São deduzidos o gradiente e a Hessiana, demonstrada a convexidade estrita e executado um passo de descida pelo método de Armijo, que reduz o custo de 1,467227 para 1,448836. Na parte computacional, implementam-se a Seção Áurea, a interpolação quadrática/cúbica protegida e a Regra de Armijo, combinadas com as direções do gradiente negativo, de Newton clássica e de Newton regularizada nos problemas TP_3, TP_7 e TP_18. As 27 combinações produziram redução estrita do custo; as 18 buscas por intervalo atingiram a tolerância prevista, e os nove passos de Armijo foram aceitos. O relatório discute diferenças entre os métodos, condicionamento, limitações da busca unidimensional e a auditoria crítica do uso de inteligência artificial.

Palavras-chave: otimização irrestrita; busca linear; Seção Áurea; interpolação cúbica; Regra de Armijo; mínimos quadrados.

Sumário

1 Introdução **3**

2 Modelagem de um problema real **3**

2.1 Contextualização e obtenção dos dados 3
2.2 Variáveis de decisão e função objetivo 4
2.3 Dedução analítica do gradiente 5
2.4 Dedução analítica da Hessiana 5
2.5 Convexidade e unicidade do minimizador 5
2.6 Primeiro passo de busca linear pela Regra de Armijo 6
2.7 Contextualização visual complementar 6

3 Experimentos nos problemas de teste **7**

3.1 Problemas atribuídos e pontos iniciais 7
3.2 Gradientes e Hessianas dos problemas de teste 8
3.3 Direções de busca e regularização de Newton 9
3.4 Métodos de busca linear 9
3.5 Protocolo experimental 10

4 Resultados e discussão **10**

4.1 Grupo G1: TP_3 10
4.2 Grupo G2: TP_7 12
4.3 Grupo G3: TP_18 14
4.4 Resumo agregado 16

5 Limitações e interpretação **16**

6 Conclusão **17**

A Manual de uso dos notebooks **17**

B Matriz de responsabilidades individuais **18**

C Transparência e auditoria crítica do uso de IA **19**

C.1 Uso de IA na modelagem real 19
C.2 Uso de IA nas simulações 19
C.3 Auditoria crítica de erro gerado na busca unidimensional 19

1 Introdução

A otimização irrestrita consiste em encontrar um vetor de parâmetros que minimize uma função escalar sem impor restrições explícitas às variáveis de decisão. Em métodos de busca linear, uma direção d_k é determinada no ponto atual x_k e um comprimento de passo $\alpha_k > 0$ é escolhido para atualizar o iterado por $x_{k+1} = x_k + \alpha_k d_k$. A escolha da direção e a escolha do passo são decisões distintas: uma direção deve, em particular, ser verificada quanto à condição de descida, enquanto o procedimento unidimensional procura um passo adequado ao longo dela [3].

O projeto proposto pelo professor Ricardo Coelho solicita duas frentes complementares: (i) estruturar um problema prático como minimização irrestrita, deduzir suas derivadas e demonstrar numericamente a primeira redução de custo; e (ii) executar três direções e três métodos de busca linear em um problema de teste de cada grupo, totalizando 27 combinações na modalidade individual de graduação [1].

A primeira frente utiliza dados históricos da VALE3 e do Ibovespa para formular uma regressão linear de retornos por mínimos quadrados. A segunda utiliza as funções TP_3, TP_7 e TP_18, com os pontos iniciais estabelecidos no enunciado. Os códigos comentados estão organizados em dois notebooks Jupyter/Google Colab, disponibilizados no repositório do projeto [5].

Os objetivos específicos são: formular a função objetivo e suas derivadas; verificar convexidade e descida; implementar explicitamente as rotinas de busca; registrar os passos, custos e pontos atualizados; comparar os resultados; e documentar tanto a responsabilidade individual quanto a assistência de inteligência artificial (IA), incluindo uma falha algorítmica identificada e corrigida.

2 Modelagem de um problema real

2.1 Contextualização e obtenção dos dados

A relação entre o retorno de uma ação e o retorno de um índice amplo de mercado é uma questão de interesse descritivo em análise de dados financeiros. Neste trabalho, a variável explicativa é o retorno do Ibovespa, denotado por m_t, e a variável resposta é o retorno da ação VALE3, denotado por r_t. O objetivo computacional não é estabelecer causalidade nem construir uma estratégia de negociação, mas ajustar uma relação linear de referência e utilizá-la como problema de otimização.

As séries históricas de preços de fechamento foram organizadas em uma base CSV. A obtenção inicial foi feita por consultas históricas à função GOOGLEFINANCE em uma planilha do Google Sheets, e a cópia utilizada no projeto foi armazenada no repositório público [2, 5]. A documentação do serviço informa que a cobertura pode variar por mercado e que os dados são fornecidos para fins informativos; por isso, o relatório trata o CSV como o retrato de dados usado na execução, sem afirmar uma auditoria independente de todas as cotações [2].

A base bruta utilizada pelo notebook possui 1.266 observações de preços entre 1º de dezembro de 2020 e 30 de dezembro de 2025. O período de dezembro de 2020 permite calcular o primeiro retorno da janela de análise, iniciada em janeiro de 2021. As datas foram convertidas de dia/mês/ano para o tipo de data do pandas, e os valores numéricos no formato brasileiro foram convertidos para números de ponto flutuante. Verificaram-se ordenação cronológica, ausência de datas duplicadas no conjunto de retornos, ausência de valores não numéricos e finitude dos dados.

Durante a inspeção e o alinhamento temporal das séries, foram realizados ajustes pontuais no arquivo CSV utilizado na análise. Foi incluída a observação de 11 de dezembro de 2025, com fechamento do Ibovespa de 159.189,10 pontos e fechamento da VALE3 de R$ 72,00. Também foram corrigidos valores de fechamento da VALE3 nas datas de 29 de outubro de 2024 (R$ 62,66), 17 de junho de 2025 (R$ 51,41) e 25 de setembro de 2025 (R$ 58,21), após consulta a registros históricos disponíveis. Esses ajustes integram a preparação da base efetivamente utilizada nos cálculos; contudo, não equivalem a uma auditoria independente e exaustiva de todas as cotações.

Por isso, os resultados devem ser interpretados considerando a base consolidada empregada no experimento.

Para uma série de preço de fechamento P_t, foi utilizado o retorno percentual simples entre pregões consecutivos:

$$R_t = 100\left(\frac{P_t}{P_{t-1}} - 1\right). \tag{1}$$

A multiplicação por 100 expressa os retornos em pontos percentuais; por exemplo, $R_t = 2$ representa variação de 2% entre os fechamentos usados. O cálculo sobre preços de fechamento, em vez de ajustar diretamente os níveis dos preços, busca modelar a co-variação de mudanças relativas e evita que a tendência dos níveis seja confundida com uma relação de retornos. Os retornos são calculados em relação ao pregão anterior disponível; portanto, não se trata de uma série com uma observação para cada dia do calendário.

Depois da seleção de janeiro de 2021 a dezembro de 2025, obtiveram-se $n = 1.246$ pares completos, de 4 de janeiro de 2021 a 30 de dezembro de 2025. A Tabela 1 resume a distribuição amostral.

Tabela 1: Estatísticas descritivas dos retornos percentuais por pregão.

Série	n	Média	Desvio-padrão	Mínimo	Máximo
Ibovespa (m_t)	1.246	0,030561	1,117516	-4,866000	5,541483
VALE3 (r_t)	1.246	0,003030	1,935462	-9,413385	10,395708

A volatilidade amostral dos retornos da VALE3 é maior que a do Ibovespa no período, como indicam os desvios-padrão. Essa comparação é estritamente descritiva e não é, por si só, uma avaliação de risco ajustada.

2.2 Variáveis de decisão e função objetivo

Adota-se o modelo linear

$$\widehat{r}_t = \alpha + \beta m_t, \tag{2}$$

em que α é o intercepto e β o coeficiente angular. As variáveis de decisão são reunidas no vetor

$$x = \begin{bmatrix}\alpha \\ \beta\end{bmatrix} \in \mathbb{R}^2.$$

O parâmetro α está em pontos percentuais de retorno da VALE3 por pregão, enquanto β é adimensional, pois relaciona dois retornos expressos na mesma unidade. O resíduo para a observação t é

$$e_t(\alpha, \beta) = \alpha + \beta m_t - r_t. \tag{3}$$

A função objetivo é a soma dos quadrados dos resíduos normalizada por $2n$:

$$f(\alpha, \beta) = \frac{1}{2n}\sum_{t=1}^{n}(\alpha + \beta m_t - r_t)^2. \tag{4}$$

O problema fica, portanto,

$$\min_{x\in\mathbb{R}^2} f(x). \tag{5}$$

O domínio é irrestrito: não são impostas condições de sinal ou limites aos parâmetros. O fator $1/(2n)$ foi escolhido por conveniência algébrica. A normalização mantém o minimizador da soma dos quadrados, divide o custo pela dimensão amostral e cancela o fator 2 ao derivar. Como f é formado pelo quadrado de retornos percentuais, sua unidade é o quadrado de ponto percentual de retorno.

Esse modelo é uma regressão linear descritiva de retornos. Não se deve interpretar automaticamente β como beta do CAPM: a especificação não usa retornos excedentes, não inclui uma taxa livre de risco e não faz uma identificação causal. Também não inclui defasagens, variáveis adicionais ou validação fora da amostra.

2.3 Dedução analítica do gradiente

Defina $e_t = \alpha + \beta m_t - r_t$. A função objetivo pode ser escrita como $f = (2n)^{-1} \sum e_t^2$. Como m_t e r_t são observações fixas durante a otimização, a regra da cadeia fornece

$$\frac{\partial f}{\partial \alpha} = \frac{1}{2n} \sum_{t=1}^{n} 2e_t \frac{\partial e_t}{\partial \alpha} = \frac{1}{n} \sum_{t=1}^{n} e_t, \tag{6}$$

$$\frac{\partial f}{\partial \beta} = \frac{1}{2n} \sum_{t=1}^{n} 2e_t \frac{\partial e_t}{\partial \beta} = \frac{1}{n} \sum_{t=1}^{n} m_t e_t. \tag{7}$$

Logo,

$$\nabla f(\alpha, \beta) = \begin{bmatrix} \frac{1}{n} \sum_{t=1}^{n} (\alpha + \beta m_t - r_t) \\ \frac{1}{n} \sum_{t=1}^{n} m_t (\alpha + \beta m_t - r_t) \end{bmatrix}. \tag{8}$$

2.4 Dedução analítica da Hessiana

Derivando novamente os componentes do gradiente, obtém-se

$$\frac{\partial^2 f}{\partial \alpha^2} = 1, \qquad \frac{\partial^2 f}{\partial \alpha \partial \beta} = \frac{1}{n} \sum_{t=1}^{n} m_t,$$

$$\frac{\partial^2 f}{\partial \beta \partial \alpha} = \frac{1}{n} \sum_{t=1}^{n} m_t, \qquad \frac{\partial^2 f}{\partial \beta^2} = \frac{1}{n} \sum_{t=1}^{n} m_t^2.$$

Assim, a Hessiana é

$$\nabla^2 f(\alpha, \beta) = \begin{bmatrix} 1 & \overline{m} \\ \overline{m} & \overline{m^2} \end{bmatrix}, \tag{9}$$

em que $\overline{m} = n^{-1} \sum_t m_t$ e $\overline{m^2} = n^{-1} \sum_t m_t^2$. A Hessiana não depende de α ou β, portanto é constante para a amostra. Essa propriedade decorre da natureza quadrática de f em relação aos parâmetros.

2.5 Convexidade e unicidade do minimizador

A Hessiana é simétrica. Para uma matriz simétrica de ordem dois, o critério de Sylvester estabelece que a positividade definida é equivalente à positividade de seus menores principais líderes. O primeiro menor é $H_{11} = 1 > 0$, enquanto

$$\det(H) = \overline{m^2} - (\overline{m})^2 \tag{10}$$

$$= \frac{1}{n} \sum_{t=1}^{n} m_t^2 - \left(\frac{1}{n} \sum_{t=1}^{n} m_t \right)^2 = \mathrm{Var}_n(m). \tag{11}$$

A variância é calculada com divisor n, conforme a definição usada na Hessiana. Nos dados observados, os resultados foram:

$$H \approx \begin{bmatrix} 1,000000 & 0,030561 \\ 0,030561 & 1,248773 \end{bmatrix},$$

$$\det(H) = 1,2478388161,$$

$$\lambda(H) \approx (0,99630074,\ 1,25247203).$$

Como ambos os menores principais líderes são positivos, $H \succ 0$. A função é estritamente convexa em $\mathbb{R}^2$ e possui um único minimizador global. A positividade dos autovalores também confirma numericamente essa conclusão. O número de condição espectral da Hessiana, aproximadamente 1,257, indica que essa matriz de segunda ordem é bem condicionada neste problema aplicado.

2.6 Primeiro passo de busca linear pela Regra de Armijo

O ponto inicial adotado é

$$x_0 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

uma referência simples que começa com intercepto nulo e inclinação unitária. Ele não é apresentado como solução ótima. A direção solicitada pelo enunciado é a direção de gradiente negativo,

$$d_0 = -\nabla f(x_0). \tag{12}$$

A avaliação numérica forneceu

$$\begin{aligned} f(x_0) &= 1,467227158980, \\ \nabla f(x_0) &\approx (0,02753063,\ 0,22010580)^T, \\ d_0 &\approx (-0,02753063,\ -0,22010580)^T, \\ \nabla f(x_0)^T d_0 &= -0,049204499731 < 0. \end{aligned}$$

O produto interno negativo comprova a condição estrita de descida. Para determinar o comprimento de passo, empregou-se Armijo com $\alpha_0 = 1$, $\rho = 0,5$ e $c = 10^{-4}$. O passo é aceito quando

$$f(x_0 + \alpha d_0) \leq f(x_0) + c\alpha \nabla f(x_0)^T d_0. \tag{13}$$

O parâmetro c controla a redução suficiente requerida em relação à aproximação linear local; ρ reduz geometricamente o passo em tentativas rejeitadas. No experimento, o primeiro candidato $\alpha = 1$ foi aceito, sem reduções. Assim,

$$\begin{aligned} x_1 &= x_0 + 1 \cdot d_0 \approx (-0,02753063,\ 0,77989420)^T, \\ f(x_1) &= 1,448836189716. \end{aligned}$$

O limite do lado direito de (13) foi 1,467222238530, maior que $f(x_1)$; a condição de Armijo foi satisfeita. A redução absoluta foi

$$f(x_0) - f(x_1) = 0,018390969265,$$

e a redução relativa foi aproximadamente 1,25345%. Portanto, a exigência de comprovar numericamente $f(x_0 + \alpha d_0) < f(x_0)$ foi atendida. O resultado representa um único passo de busca linear, não uma execução iterativa até convergência.

2.7 Contextualização visual complementar

A Figura 1 apresenta os pares de retornos da amostra e, apenas como referência descritiva complementar, a reta de mínimos quadrados calculada diretamente sobre o mesmo retrato de dados. Esse ajuste auxiliar fornece $\widehat{\alpha} = -0,02216064$ e $\widehat{\beta} = 0,82428464$, com $R^2 \approx 0,2265$ e custo mínimo de referência $f_{\min} \approx 1,44758413$. Esse cálculo por mínimos quadrados é uma conferência complementar e não deve ser confundido com o passo de Armijo, que foi o experimento solicitado para a modelagem prática.

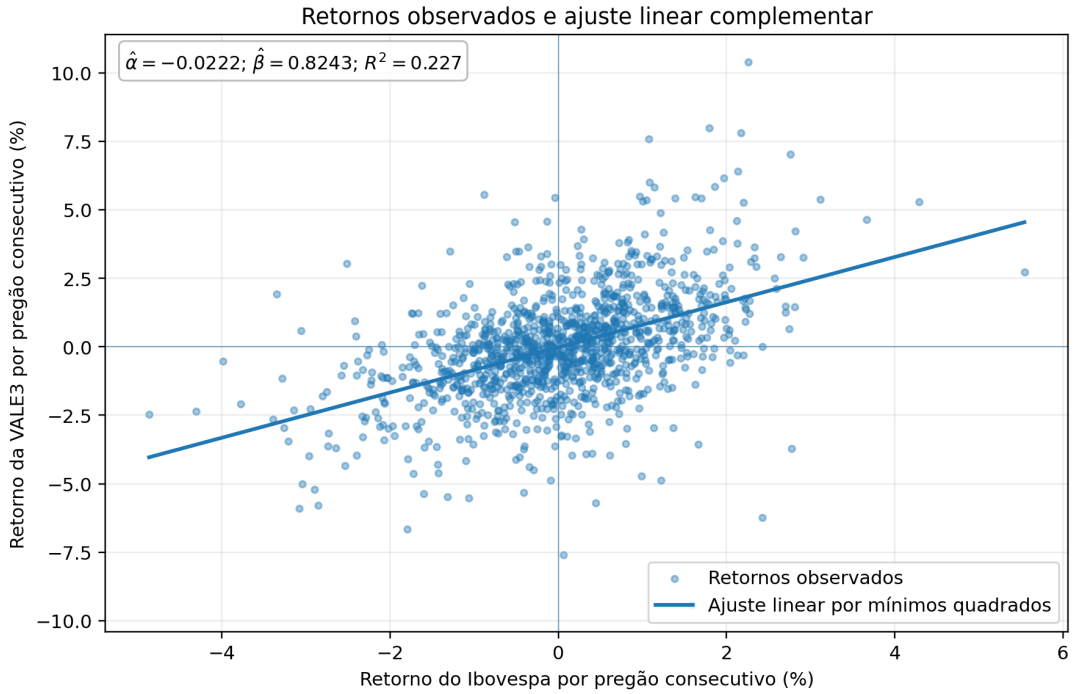


Figura 1: Retornos por pregão consecutivo de VALE3 e Ibovespa. A reta é um ajuste linear complementar calculado por mínimos quadrados sobre a mesma amostra; não é saída do passo de Armijo.

O valor de R^2 indica que, nesta amostra, o ajuste linear simples descreve cerca de 22,65% da variabilidade amostral dos retornos da VALE3. O resultado sugere uma associação positiva, mas deixa uma parcela substancial da variação sem explicação. Não constitui uma recomendação financeira, inferência causal ou teste de estabilidade temporal.

3 Experimentos nos problemas de teste

3.1 Problemas atribuídos e pontos iniciais

Na modalidade individual de graduação, o enunciado requer um problema de cada grupo e nove combinações por problema, totalizando 27 execuções [1]. Foram utilizados os pontos iniciais atribuídos:

- **TP_3 (G1):** $f_3(x) = x_1^2 + 2x_2^2 + 3x_3^2 - 2x_1x_2$, com $x_0 = (1, 1, 1)^T$;
- **TP_7 (G2):** $f_7(x) = A(x)^2 + B(x)^2$, com $x_0 = (15, -2)^T$, em que $A(x) = -13 + x_1 + 5x_2^2 - x_2^3 - 2x_2$ e $B(x) = -29 + x_1 + x_2^3 + x_2^2 - 14x_2$;
- **TP_18 (G3):** $f_{18}(x) = (x_1 - 1)^4 + 10^4(x_2 - x_1^2)^2$, com $x_0 = (2, 2)^T$.

O enunciado caracteriza G1 por curvatura positiva em todo o domínio e minimizador global único; G2 por possíveis vales não lineares, múltiplos pontos estacionários e regiões de curvatura negativa; e G3 por Hessianas com número de condição alto, curvas de nível alongadas e oscilação do gradiente [1]. Essas são propriedades gerais usadas na organização do catálogo e não devem ser presumidas automaticamente para cada ponto inicial isolado.

3.2 Gradientes e Hessianas dos problemas de teste

Para TP_3, o gradiente e a Hessiana são

$$\nabla f_3(x) = \begin{bmatrix} 2x_1 - 2x_2 \\ 4x_2 - 2x_1 \\ 6x_3 \end{bmatrix}, \qquad H_3 = \begin{bmatrix} 2 & -2 & 0 \\ -2 & 4 & 0 \\ 0 & 0 & 6 \end{bmatrix}.$$

Em $x_0 = (1,1,1)^T$, $f_3(x_0) = 4$ e $\nabla f_3(x_0) = (0,2,6)^T$.

Para TP_7, escreva $f_7 = A^2 + B^2$. Com

$$A' = 10x_2 - 3x_2^2 - 2, \quad B' = 3x_2^2 + 2x_2 - 14,$$

$$A'' = 10 - 6x_2, \quad B'' = 6x_2 + 2,$$

obtêm-se

$$\nabla f_7(x) = \begin{bmatrix} 2(A+B) \\ 2(AA' + BB') \end{bmatrix}$$

e

$$H_7(x) = \begin{bmatrix} 4 & 2(A'+B') \\ 2(A'+B') & 2((A')^2 + AA'' + (B')^2 + BB'') \end{bmatrix}.$$

No ponto inicial, $f_7(x_0) = 1256$, $\nabla f_7(x_0) = (88, -2432)^T$ e

$$H_7(x_0) = \begin{bmatrix} 4 & -80 \\ -80 & 3680 \end{bmatrix}.$$

Para TP_18, denote $q = x_2 - x_1^2$. Então

$$\nabla f_{18}(x) = \begin{bmatrix} 4(x_1-1)^3 - 4 \cdot 10^4 x_1 q \\ 2 \cdot 10^4 q \end{bmatrix},$$

e

$$H_{18}(x) = \begin{bmatrix} 12(x_1-1)^2 - 4 \cdot 10^4 (x_2 - 3x_1^2) & -4 \cdot 10^4 x_1 \\ -4 \cdot 10^4 x_1 & 2 \cdot 10^4 \end{bmatrix}.$$

Em $x_0 = (2,2)^T$, $f_{18}(x_0) = 40001$, $\nabla f_{18}(x_0) = (160004, -40000)^T$ e

$$H_{18}(x_0) = \begin{bmatrix} 400012 & -80000 \\ -80000 & 20000 \end{bmatrix}.$$

As derivadas implementadas foram comparadas com aproximações por diferenças finitas centrais. A Tabela 2 apresenta os erros relativos obtidos; todos permaneceram na ordem de 10^{-10} ou menores, apoiando a consistência das expressões analíticas e da implementação numérica.

Tabela 2: Erros relativos máximos da validação numérica das derivadas nos pontos iniciais.

Problema	Gradiente	Hessiana
TP_3	$2,223 \times 10^{-12}$	$1,861 \times 10^{-12}$
TP_7	$4,675 \times 10^{-11}$	$3,389 \times 10^{-11}$
TP_18	$5,586 \times 10^{-11}$	$1,732 \times 10^{-11}$

3.3 Direções de busca e regularização de Newton

Foram construídas três direções em cada x_0:

$$d_G = -\nabla f(x_0), \tag{14}$$

$$d_N = -[H(x_0)]^{-1}\nabla f(x_0), \tag{15}$$

$$d_M = -[H(x_0) + \mu I]^{-1}\nabla f(x_0). \tag{16}$$

Na implementação, os sistemas lineares foram resolvidos numericamente em vez de calcular as inversas explicitamente. Para a direção modificada, o parâmetro de regularização usa o menor autovalor $\lambda_{\min}$ e a escala $s = \max(1, \|H\|_2)$:

$$\mu_{\min} = 10^{-6}s, \qquad \delta = 10^{-8}s, \qquad \mu = \max\{\mu_{\min}, -\lambda_{\min} + \delta\}.$$

A expressão garante margem positiva para a Hessiana regularizada e acrescenta regularização positiva mesmo quando a Hessiana original já é positiva definida. Os valores usados foram $\mu = 6 \times 10^{-6}$ para TP_3, $\mu = 0,0036817402$ para TP_7 e $\mu = 0,41616681$ para TP_18. Em todos os três pontos iniciais, as Hessianas clássicas já eram positivas definidas; assim, Newton clássico também produziu direção de descida.

Tabela 3: Espectro e número de condição das Hessianas nos pontos iniciais.

Problema	$\lambda_{\min}$	$\lambda_{\max}$	$\kappa_2(H)$
TP_3	0,763932	6,000000	7,8541
TP_7	2,259801	3681,740199	1629,2321
TP_18	3845,188894	416166,811106	108,2305

A verificação da condição $\nabla f(x_0)^T d < 0$ produziu os resultados da Tabela 4. O sinal foi estritamente negativo para todas as direções. Esse teste é independente do método de busca de passo: uma busca linear é iniciada apenas após calcular e verificar a direção.

Tabela 4: Produtos direcionais nos três pontos iniciais.

Problema	$\nabla f^T d_G$	$\nabla f^T d_N$	$\nabla f^T d_M$
TP_3	-40	-8	$-7,999982$
TP_7	$-5,922368 \times 10^{6}$	$-2153,1077$	$-2152,2198$
TP_18	$-2,720128 \times 10^{10}$	-80000	$-79998,336$

Dois cuidados interpretativos são importantes. Primeiro, a Hessiana de TP_7 é positiva definida em x_0, embora a categoria G2 admita regiões de curvatura negativa em outras regiões do domínio. Segundo, o número de condição da Hessiana de TP_18 no ponto inicial é aproximadamente 108,23, inferior a 10^3. A classificação TP_18 como G3 segue a atribuição do enunciado, mas o cálculo local apresentado aqui não confirma, por si só, a afirmação de condicionamento extremamente alto naquele ponto específico.

3.4 Métodos de busca linear

Seção Áurea. O método reduz um intervalo que contém um mínimo da função unidimensional. Na implementação, o passo de referência é escalado pela norma da direção, $\alpha_0 = 1/\max(1, \|d\|_2)$. Se o primeiro passo não reduzir a função, o comprimento é reduzido pela metade até obter uma redução estrita; em seguida, o passo é expandido até delimitar uma região de mínimo. O intervalo é refinado com a razão áurea $\tau = (\sqrt{5} - 1)/2$ até alcançar largura relativa de 10^{-8} ou o limite de 200 iterações. A delimitação dispõe de até 100 reduções e 60 expansões.

Interpolação quadrática/cúbica. O método usa valores da função e derivadas direcionais nos extremos para construir uma interpolação cúbica de Hermite. Se não houver uma proposta cúbica admissível no interior seguro do intervalo, a rotina tenta uma interpolação quadrática e, como salvaguarda, recorre ao ponto médio. A mesma estratégia de passo escalado e delimitação é usada; a tolerância relativa é 10^{-8}, com no máximo 100 iterações, 100 reduções iniciais e 60 expansões. Portanto, o procedimento efetivamente implementado é uma busca aproximada e protegida por interpolação, não uma garantia de minimização exata de ϕ para uma função não unimodal.

Regra de Armijo. Armijo realiza retrocesso a partir de $\alpha_0 = 1$. Um passo é aceito se satisfizer a desigualdade (13); caso contrário, o comprimento é multiplicado por $\rho = 0,5$. O parâmetro de suficiência é $c = 10^{-4}$, o número máximo de tentativas é 100 e a busca é interrompida se o comprimento ficar abaixo de 10^{-14}. Como Armijo é inexato, o critério de sucesso é a aceitação do passo, não a convergência ao minimizador de ϕ.

Em todas as três rotinas, a função unidimensional é $\phi(\alpha) = f(x_0 + \alpha d)$ para $\alpha \geq 0$. As buscas da Seção Áurea e da interpolação pressupõem que o intervalo delimitado tenha um comportamento compatível com uma região de mínimo unimodal; essa hipótese é uma limitação relevante em funções com múltiplos vales. Os critérios de parada internos diferem, de modo que os contadores de iterações/tentativas não equivalem ao número de avaliações da função e não devem ser interpretados como uma medida perfeitamente comparável de custo computacional entre os métodos.

3.5 Protocolo experimental

Cada problema foi avaliado com as três direções e cada direção foi combinada com os três métodos. A quantidade de combinações é, portanto,

$$3 \text{ problemas} \times 3 \text{ direções} \times 3 \text{ métodos} = 27.$$

As rotinas registram o produto direcional, a direção de descida, o comprimento do passo α, o custo inicial e final, a redução, o número de iterações internas, o novo ponto e o critério de término. Para Seção Áurea e interpolação, registrou-se a convergência do intervalo; para Armijo, o critério relevante é a satisfação da desigualdade de aceitação.

4 Resultados e discussão

4.1 Grupo G1: TP_3

No TP_3, a função é quadrática e sua Hessiana é constante e positiva definida. A direção de Newton clássica leva ao minimizador $x^* = (0, 0, 0)^T$ em um passo unitário; por isso, as buscas baseadas em minimização unidimensional e Armijo aceitam $\alpha = 1$ ou retornam um custo numericamente indistinguível de zero. Esse é um caso de referência em que as propriedades quadráticas favorecem a direção de Newton.

Tabela 5: Resultados das nove combinações para TP_3.

Direção	Método	α	$f(x_1)$	$f(x_0) - f(x_1)$	Iterações/tentativas	Novo ponto x_1
d_G	Áurea	0.172414	0.551724	3.448276	41	$(1,\ 0.65517,\ -0.034483)$
d_G	Interpolação	0.172414	0.551724	3.448276	26	$(1,\ 0.65517,\ -0.034483)$
d_G	Armijo	0.250000	1.250000	2.750000	3	$(1,\ 0.5,\ -0.5)$
d_N	Áurea	1.000000	$4.01e-19$	4.000000	42	$(0,\ 0,\ 0)$
d_N	Interpolação	1.000000	0	4.000000	1	$(0,\ 0,\ 0)$
d_N	Armijo	1.000000	0	4.000000	1	$(0,\ 0,\ 0)$
d_M	Áurea	1.000002	$2.77e-11$	4.000000	42	$(6.75e-06,\ 3.75e-06,\ -1.25e-06)$
d_M	Interpolação	1.000002	$2.77e-11$	4.000000	28	$(6.75e-06,\ 3.75e-06,\ -1.25e-06)$
d_M	Armijo	1.000000	$4.80e-11$	4.000000	1	$(9e-06,\ 6e-06,\ 1e-06)$

Na direção do gradiente negativo, Seção Áurea e interpolação encontraram $\alpha \approx 0,172414$ e custo $f(x_1) \approx 0,551724$, enquanto Armijo aceitou $\alpha = 0,25$ e custo 1,25. A diferença é esperada: as duas primeiras rotinas procuram aproximar o minimizador da função unidimensional, enquanto Armijo aceita o primeiro passo que satisfaz uma redução suficiente. Para Newton modificada, o pequeno μ produz uma direção muito próxima da Newton clássica e, consequentemente, resultados quase idênticos.

4.2 Grupo G2: TP_7

TP_7 começa com custo 1256. As três direções são descidas válidas, mas os comprimentos de passo e os custos obtidos variam. Na direção do gradiente negativo, Seção Áurea e interpolação retornam $\alpha \approx 5,42 \times 10^{-4}$ e custo de aproximadamente 54,4493. Armijo aceita $\alpha \approx 1,953 \times 10^{-3}$, obtendo custo 769,1533. O passo aceito por Armijo é suficiente, mas não tão agressivo na redução quanto aquele obtido pelas buscas que refinam um mínimo de linha.

Com Newton clássica, Seção Áurea e interpolação obtêm comprimentos próximos a 1,065421 e custos finais de aproximadamente 133,184; Armijo aceita $\alpha = 1$ e termina em aproximadamente 137,254. A regularização muda ligeiramente a direção e produz resultados próximos, com custo em torno de 132,945 nas duas buscas por intervalo. Esses resultados representam um único passo a partir de x_0 e não demonstram convergência ao minimizador global de TP_7. A possibilidade de múltiplos estacionários torna inadequado inferir globalidade a partir de uma única atualização.

Tabela 6: Resultados das nove combinações para TP_7.

Direção	Método	α	$f(x_1)$	$f(x_0) - f(x_1)$	Iterações/tentativas	Novo ponto x_1
d_G	Áurea	5.42092×10^{-4}	54.449343	1201.550657	41	$(14.952,\ -0.68163)$
d_G	Interpolação	5.42092×10^{-4}	54.449343	1201.550657	26	$(14.952,\ -0.68163)$
d_G	Armijo	0.001953	769.153320	486.846680	10	$(14.828,\ 2.75)$
d_N	Áurea	1.065421	133.183901	1122.816099	41	$(-1.555,\ -1.6558)$
d_N	Interpolação	1.065421	133.183901	1122.816099	24	$(-1.555,\ -1.6558)$
d_N	Armijo	1.000000	137.254303	1118.745697	1	$(-0.53846,\ -1.6769)$
d_M	Áurea	1.066204	132.945482	1123.054518	41	$(-1.5403,\ -1.6549)$
d_M	Interpolação	1.066204	132.945482	1123.054518	24	$(-1.5403,\ -1.6549)$
d_M	Armijo	1.000000	137.108001	1118.891999	1	$(-0.51321,\ -1.6764)$

4.3 Grupo G3: TP_18

TP_18 apresenta um termo ponderado por 10^4 e grande magnitude do gradiente inicial. Na direção do gradiente negativo, o passo selecionado pelas buscas por intervalo é da ordem de 10^{-6}; essa escala pequena demonstra por que a normalização do passo inicial e a delimitação cuidadosa do intervalo são relevantes. Seção Áurea e interpolação encontraram custo próximo de 0,045193, reduzindo o valor inicial 40001 em mais de 39999 unidades. Armijo aceitou um passo maior e ainda obteve uma redução substancial, mas seu custo final foi cerca de 28829,316: a condição de suficiência não equivale à minimização exata da função de linha.

Para Newton clássica, as três buscas aceitam $\alpha \approx 1$ e alcançam custo de aproximadamente 0,9998. A direção de Newton regularizada produz resultados praticamente iguais, dado que a regularização é pequena relativamente à escala da Hessiana. Neste teste, isso ilustra que a direção de Newton consegue alinhar rapidamente o componente associado à diferença $x_2 - x_1^2$, enquanto o custo residual é dominado principalmente pelo termo $(x_1 - 1)^4$.

Tabela 7: Resultados das nove combinações para TP_18.

Direção	Método	α	$f(x_1)$	$f(x_0) - f(x_1)$	Iterações/tentativas	Novo ponto x_1
d_G	Áurea	3.36823×10^{-6}	0.045193	40000.954807	42	(1.4611, 2.1347)
d_G	Interpolação	3.36823×10^{-6}	0.045193	40000.954807	26	(1.4611, 2.1347)
d_G	Armijo	7.62939×10^{-6}	28829.316314	11171.683686	18	(0.77927, 2.3052)
d_N	Áurea	1.000000	0.999800	40000.000200	41	(2, 3.9998)
d_N	Interpolação	1.000000	0.999800	40000.000200	25	(2, 3.9998)
d_N	Armijo	1.000000	0.999800	40000.000200	1	(2, 3.9998)
d_M	Áurea	1.000021	0.999634	40000.000366	41	(1.9999, 3.9996)
d_M	Interpolação	1.000021	0.999634	40000.000366	26	(1.9999, 3.9996)
d_M	Armijo	1.000000	0.999651	40000.000349	1	(1.9999, 3.9996)

4.4 Resumo agregado

A consolidação confirmou 27 combinações únicas, 27 direções de descida válidas, 27 reduções estritas da função objetivo e nenhuma exceção de execução. As 18 buscas por intervalo atingiram a tolerância relativa definida nas rotinas; os nove passos de Armijo satisfizeram a condição de aceitação. Esse resultado é uma verificação do comportamento do primeiro passo para os pontos especificados, não uma afirmação de que todos os algoritmos tenham convergido a uma solução final global.

Tabela 8: Resumo das 27 execuções.

Problema	Execuções	Sucessos	Falhas	$f(x_0)$	Menor $f(x_1)$ observado
TP_3	9	9	0	4	≈ 0
TP_7	9	9	0	1256	54,449343
TP_18	9	9	0	40001	0,045193
Total	27	27	0	–	–

A Figura 2 destaca o caso TP_18 com d_G. O mínimo estreito em torno de $\alpha \approx 3,368 \times 10^{-6}$ é identificado pelas buscas por intervalo; o passo de Armijo está em outra região da curva, ainda satisfazendo seu critério de redução suficiente.

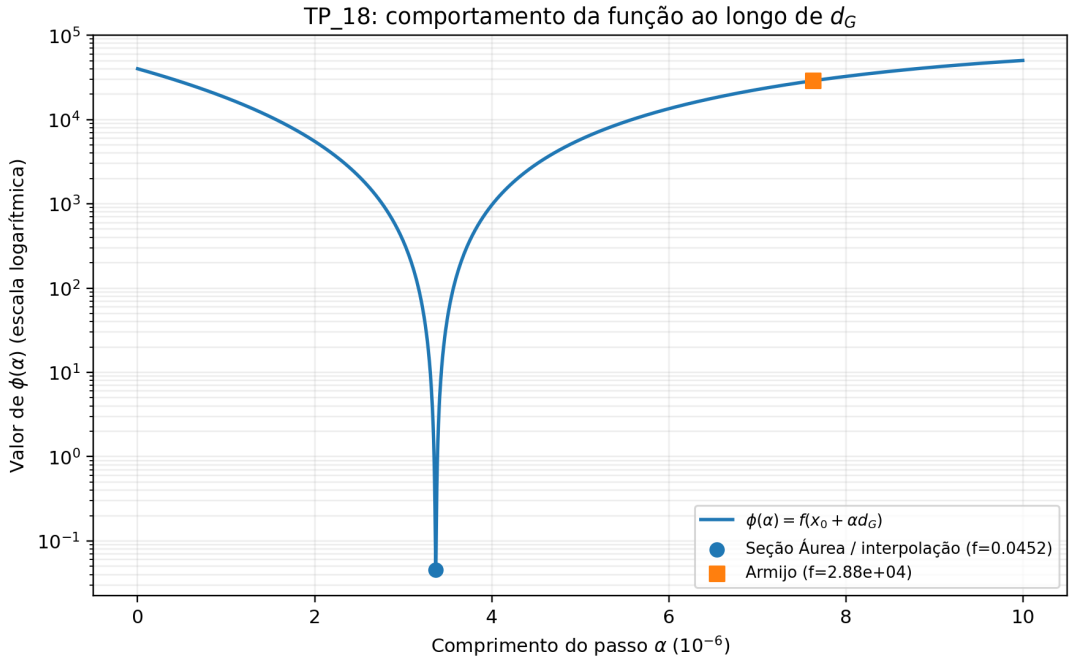


Figura 2: Função unidimensional para TP_18 a partir do ponto inicial e direção do gradiente negativo. O eixo do custo usa escala logarítmica para tornar visíveis valores desde cerca de 10^{-2} até dezenas de milhares.

5 Limitações e interpretação

A modelagem financeira é intencionalmente simples: usa dois ativos/séries, retornos contemporâneos, relação linear e uma única janela temporal. Não considera retorno excedente, defasagens, eventos corporativos, variáveis macroeconômicas, heterocedasticidade ou avaliação fora da amostra. O coeficiente angular deve ser lido dentro dessa especificação e não como uma estimativa de risco

causal ou uma recomendação de investimento. A fonte de dados é um retrato salvo no repositório; a integridade de tipo, data e valores finitos foi verificada computacionalmente, mas não foi feita uma auditoria independente de todas as cotações contra registros oficiais da bolsa.

As simulações testam somente um passo em cada combinação, conforme o escopo do enunciado. Assim, uma grande redução não é o mesmo que convergência, e uma pequena redução não significa falha quando o método satisfaça seu critério. Os contadores das buscas são internos a algoritmos diferentes e não medem de forma idêntica número de avaliações, tempo real ou complexidade total. A Seção Áurea pressupõe unimodalidade no intervalo e a interpolação depende das aproximações polinomiais e salvaguardas; em problemas com múltiplos vales, o intervalo escolhido influencia o resultado.

No TP_7 e TP_18, o fato de as Hessianas serem positivas definidas nos pontos iniciais não elimina comportamentos não convexos possíveis em outras regiões. Da mesma forma, a classificação atribuída pelo catálogo deve ser reportada como fornecida pelo professor, mas diagnósticos numéricos locais devem ser apresentados com os valores efetivamente calculados. O número de condição da Hessiana de TP_18 em x_0 foi 108,23, embora o enunciado a coloque em G3; isso foi explicitado sem alterar a atribuição do problema.

6 Conclusão

O projeto formulou uma minimização irrestrita a partir de retornos de VALE3 e Ibovespa, deduziu gradiente e Hessiana, comprovou positividade definida e executou um passo de Armijo com redução de custo de aproximadamente 1,25345%. Esse conjunto atende aos requisitos de modelagem, de primeira e segunda ordem, discussão de convexidade e comprovação de uma primeira redução.

Na parte de problemas de teste, as implementações explícitas da Seção Áurea, da interpolação quadrática/cúbica protegida e de Armijo foram combinadas com gradiente negativo, Newton clássica e Newton regularizada em TP_3, TP_7 e TP_18. As 27 execuções produziram redução estrita, com comportamentos distintos: a direção de Newton resolveu o caso quadrático TP_3 em um passo, os métodos diferiram mais visivelmente em TP_7 e a escala do passo foi crítica no TP_18 com gradiente negativo. A revisão do código evidenciou que uma busca linear deve ser validada não apenas pela ocorrência de redução, mas também pela delimitação do intervalo e pelo critério de parada.

Por fim, o registro de IA mostra que a ferramenta foi utilizada como apoio de modelagem, implementação e revisão, e não como autoridade infalível. A falha na delimitação inicial de intervalo foi detectada por comparação numérica ao longo da mesma direção e corrigida antes da consolidação final. A auditoria de derivadas e a análise das saídas foram componentes essenciais para a confiabilidade do resultado.

A Manual de uso dos notebooks

O código-fonte comentado está organizado em dois notebooks do repositório do projeto: ‘01_modelagem_real.ipynb‘, dedicado à preparação das cotações, cálculo de retornos e passo de Armijo; e ‘02_experimentos_pnl.ipynb‘, dedicado às funções de teste, derivadas, direções, três buscas lineares e consolidação das 27 execuções [5]. O relatório contém o roteiro abaixo para que as saídas sejam reproduzidas e interpretadas.

1. Abra o repositório indicado nas referências e acesse os notebooks. Para o primeiro notebook, permita acesso à internet no Colab, pois a célula de carga lê a versão CSV armazenada no repositório. A base contém valores históricos e é mantida como snapshot.

2. Reinicie o ambiente do notebook e execute as células de cima para baixo. Essa ordem define

bibliotecas, dados, funções, gradientes e Hessianas antes das células que dependem deles.

3. No notebook de modelagem, confira as dimensões dos dados, a janela de retornos, as estatísticas, o determinante da Hessiana, os autovalores, o produto direcional e a verificação da desigualdade de Armijo.
4. No notebook de simulações, confira os valores de $f(x_0)$, a validação numérica das derivadas, os produtos $\nabla f(x_0)^T d$ e o parâmetro μ. Depois execute TP_3, TP_7, TP_18 e a célula final de consolidação.
5. Na tabela de cada problema, 'alpha' é o comprimento de passo escolhido; 'f(x0)' e 'f(x1)' são os custos antes e depois; 'Redução' é $f(x_0) - f(x_1)$; 'Iterações' é o contador interno do método; 'Status' indica redução estrita; 'Critério atingido' registra aceitação/término; e 'Convergência do intervalo' aplica-se às buscas por Seção Áurea e interpolação, sendo não aplicável a Armijo.
6. A tabela final deve conter 27 combinações únicas, 27 direções de descida válidas e 27 reduções estritas. Os números podem variar em últimas casas decimais em função de ambiente e tolerâncias; mudanças materiais exigem reexaminar a fonte de dados e a implementação.

Os parâmetros principais são explícitos nas funções: para Armijo, $\alpha_0 = 1$, $\rho = 0,5$, $c = 10^{-4}$, máximo de 100 tentativas e passo mínimo de 10^{-14}; para Seção Áurea e interpolação, tolerância relativa de 10^{-8}, junto dos limites de expansão, redução e iterações documentados nos comentários das funções. Não é necessário inserir valores externos em uma interface: os pontos iniciais, funções e parâmetros estão definidos no código.

B Matriz de responsabilidades individuais

A atividade foi realizada na modalidade individual. Por isso, não há divisão entre integrantes; a matriz explicita a responsabilidade única do autor, ao mesmo tempo em que identifica a IA apenas como recurso auxiliar, jamais como substituta da verificação e responsabilidade acadêmica do estudante.

Tabela 9: Matriz de responsabilidades do projeto individual.

Atividade	Responsável pela realização e validação	Apoio de IA
Escolha e formulação da modelagem real	João Ivo Rocha Alves (581734)	Discussão de alternativas e revisão
Preparação, conversão e inspeção dos dados	João Ivo Rocha Alves (581734)	Sugestões de validação e depuração
Dedução e validação das derivadas	João Ivo Rocha Alves (581734)	Revisão algébrica e teste numérico sugerido
Implementação das direções e buscas lineares	João Ivo Rocha Alves (581734)	Geração inicial de código, submetido a auditoria
Execução das 27 simulações e conferência	João Ivo Rocha Alves (581734)	Ajuda para análise de saídas e correção de bug
Redação e conclusão do relatório	João Ivo Rocha Alves (581734)	Apoio de estruturação e revisão textual

C Transparência e auditoria crítica do uso de IA

O enunciado permite e incentiva o uso de modelos de linguagem como assistentes, mas exige registro de solicitações e análise crítica de ao menos um erro produzido pelo modelo [1]. Este apêndice separa explicitamente a assistência utilizada na modelagem real daquela usada nas simulações. Os itens a seguir resumem as principais solicitações feitas durante o desenvolvimento; são resumos por finalidade, não transcrições literais exaustivas de todo o histórico de conversas.

C.1 Uso de IA na modelagem real

A assistência de IA foi usada para discutir uma formulação prática compatível com minimização irrestrita; organizar a relação entre retornos de VALE3 e Ibovespa; estruturar a função de mínimos quadrados; revisar a dedução do gradiente e da Hessiana; interpretar a positividade definida e a convexidade; sugerir a organização das células do notebook; e implementar/verificar um primeiro passo de Armijo. As solicitações também incluíram revisão dos resultados impressos, explicação dos parâmetros c e ρ, e orientação para separar a implementação computacional no notebook da justificativa econômica e metodológica no relatório.

A contribuição da ferramenta não substituiu a definição do tema, o fornecimento/seleção da base, a execução do notebook ou as verificações numéricas. O autor conferiu os retornos e os valores do custo, executou as células e utilizou a relação entre determinante da Hessiana e variância dos retornos do Ibovespa como uma verificação independente da fórmula analítica. A decisão de não interpretar β como CAPM também decorre das variáveis efetivamente presentes na especificação.

C.2 Uso de IA nas simulações

Na parte dos problemas de teste, a IA auxiliou na transcrição das funções do enunciado, elaboração das derivadas de TP_3, TP_7 e TP_18, construção das direções de gradiente e Newton, escolha e implementação da regularização, implementação das três rotinas de busca linear e estruturação de uma rotina que executa automaticamente as 27 combinações. Também foi utilizada para revisar as tabelas, distinguir aceitação de Armijo da convergência de uma minimização unidimensional, organizar a estrutura dos capítulos por grupo e planejar as verificações que precederam a consolidação final.

As decisões de manter as funções de busca visíveis no código, validar o sinal de $\nabla f(x_0)^T d$ e comparar as derivadas com diferenças finitas foram tomadas para tornar as rotinas auditáveis. A IA produziu sugestões e versões iniciais; o código final foi iterativamente executado, confrontado com resultados numéricos e corrigido após comportamento inconsistente.

C.3 Auditoria crítica de erro gerado na busca unidimensional

Uma falha concreta apareceu na primeira versão sugerida pelo modelo para a Seção Áurea e a interpolação. No TP_18, usando a direção do gradiente negativo, as rotinas iniciais encontraram um passo próximo de $2,32 \times 10^{-5}$ e custo da ordem de 54. Esse resultado satisfazia apenas a condição de redução estrita a partir do custo inicial 40001; não era suficiente para estabelecer que a busca havia localizado adequadamente uma região de mínimo da função unidimensional.

A inconsistência foi identificada durante a revisão das saídas: mantendo a mesma função, o mesmo ponto e a mesma direção, a avaliação de um passo menor, em torno de $3,36823 \times 10^{-6}$, produziu custo próximo de $0,045193$, muito inferior. Assim, a conclusão inicial de sucesso era excessiva. O defeito estava na estratégia de delimitação: se o primeiro teste apresentasse custo superior ao valor inicial, a versão anterior aceitava imediatamente um intervalo amplo $[0, 1]$, sem confirmar que a hipótese de unimodalidade era razoável nesse intervalo. A magnitude muito elevada da direção no TP_18 tornava particularmente problemática a escala inicial unitária.

A correção alterou a inicialização para $\alpha_0 = 1/\max(1, \|d\|_2)$, acrescentou redução progressiva do passo até observar redução estrita, delimitou a região de mínimo com expansão progressiva e passou a usar uma tolerância relativa à escala do próprio passo. Na interpolação, foram mantidas salvaguardas de interpolação quadrática e ponto médio quando a proposta cúbica não era admissível. Após a modificação, as duas rotinas obtiveram $f(x_1) \approx 0,0451926753$ no caso TP_18/d_G, e a tabela de 27 experimentos foi gerada novamente.

Essa auditoria mostra por que a saída de um algoritmo gerado por IA não pode ser aceita apenas porque o código termina ou porque a função diminui. Foi necessário comparar passos na mesma direção, analisar a forma da função de linha, reconhecer a importância de delimitar o intervalo e distinguir redução de custo de atendimento ao critério de parada. A falha e a correção foram registradas como parte do processo de validação, em conformidade com a exigência de transparência ativa.

Declaração final sobre autoria e IA

O trabalho foi desenvolvido individualmente por João Ivo Rocha Alves. Ferramentas de IA foram utilizadas como apoio à formulação, programação, revisão e redação. A responsabilidade pela escolha dos dados, decisões metodológicas, execução e validação das rotinas, interpretação dos resultados e versão submetida permanece com o autor. Os casos em que uma sugestão gerada por IA foi inadequada foram mantidos no registro crítico acima, em vez de ocultados.

Referências

[1] COELHO, Ricardo. *Primeiro Projeto Computacional: Modelagem e Busca Linear*. Universidade Federal do Ceará, Bacharelado em Ciência de Dados, disciplina Programação Não Linear, 2026. Enunciado da atividade disponibilizado pelo professor.

[2] GOOGLE. *GOOGLEFINANCE: Ajuda dos Editores do Google Docs*. Disponível em: https://support.google.com/docs/answer/3093281?hl=pt-BR. Acesso em: 23 out. 2026.

[3] NOCEDAL, Jorge; WRIGHT, Stephen J. *Numerical Optimization*. 2. ed. New York: Springer, 2006. DOI: https://doi.org/10.1007/978-0-387-40065-5.

[4] HARRIS, Charles R. et al. Array programming with NumPy. *Nature*, v. 585, p. 357–362, 2020. DOI: https://doi.org/10.1038/s41586-020-2649-2.

[5] ALVES, João Ivo Rocha. *Projeto PNL – busca linear: notebooks e base de dados*. Repositório de código do projeto. Disponível em: https://github.com/JoaoIvo15/projeto-pnl-busca-linear. Acesso em: 23 out. 2026.